

# Relatório de Análise de Resultados

## Régressão Logística e Algoritmos Genéticos

### Tech Challenger 2 - Fase 2

Gerado em: 14/01/2026 14:35:46

## Relatório Técnico: Otimização de Modelo de Régressão Logística com Algoritmos Genéticos para Diagnóstico de Diabetes

### 1. Resumo Executivo

Este relatório aborda a otimização de um modelo de Régressão Logística para diagnóstico de diabetes utilizando Algoritmos Genéticos (AGs). O processo de otimização focou na melhoria do recall do modelo, crucial para reduzir o número de diagnósticos incorretos. A análise demonstra um aumento significativo na capacidade de detecção de casos positivos, evidenciado pela melhoria no recall de 0,50 para 0,81 após a aplicação dos AGs.

### 2. Análise da Evolução do Algoritmo Genético

O gráfico de evolução da função de fitness ao longo das gerações mostra uma estabilidade em torno do valor de 820. Essa observação sugere que o algoritmo rapidamente atingiu um platô de otimização, mantendo a melhor aptidão sem melhorias adicionais substanciais ao longo das gerações. Isso pode indicar uma possível convergência prematura, ou que o espaço de busca estava bem explorado.

### 3. Análise Comparativa dos Modelos

A aplicação dos AGs resultou em uma melhoria significativa no desempenho do modelo otimizado em relação ao modelo original.

- **Modelo Original:**

- Recall: 0,50
- Falsos Positivos: 20
- Falsos Negativos: 27

- **Modelo Otimizado (AG):**

- Recall: 0,81
- Falsos Positivos: 33
- Falsos Negativos: 10

O modelo otimizado apresenta um recall superior, essencial para o diagnóstico bem-sucedido de diabetes, reduzindo falsos negativos que podem levar a diagnósticos errados.

## 4. Análise das Matrizes de Confusão

As matrizes de confusão revelam a mudança no equilíbrio de classificações corretas e incorretas:

- O modelo otimizado conseguiu aumentar os verdadeiros positivos (44 vs 27 no modelo original) e diminuiu significativamente os falsos negativos (10 vs 27), melhorando o diagnóstico correto de casos positivos de diabetes.
- Houve um aumento nos falsos positivos (33 vs 20), que, embora aumente a carga de investigações adicionais, é compensado pela redução dos falsos negativos críticos.

## 5. Análise das Métricas de Performance

A melhoria nas métricas de performance reforça a eficácia da otimização:

- **Recall:** Aumento de 0,50 para 0,81 demonstra uma sensibilidade melhorada, essencial para detectar o máximo possível de casos de diabetes.

- **Falsos Negativos:** Redução de 27 para 10, reduzindo o risco de diagnósticos não detectados.

- **Falsos Positivos:** Incremento de 20 para 33, que deve ser gerido em termos de impacto em investigações e tratamento médico.

## 6. Conclusões e Insights

A aplicação de Algoritmos Genéticos para otimizar o modelo de Regressão Logística resultou em uma melhoria significativa na capacidade de detecção de diabetes, conforme evidenciado pelo aumento do recall e a redução dos falsos negativos. Recomenda-se explorar ajustes nos parâmetros dos AGs para possivelmente reduzir falsos positivos, mantendo ou melhorando os ganhos em recall.

## 7. Impacto Prático

Os resultados deste estudo têm implicações significativas para o diagnóstico clínico. Ao melhorar o recall e reduzir falsos negativos, o modelo otimizado possibilita um diagnóstico mais confiável, reduzindo riscos associados a diagnósticos incorretos de diabetes. Implementar esses modelos ajustados em ambientes clínicos pode aprimorar significativamente a triagem e o gerenciamento de casos suspeitos de diabetes.

## Top 5 Configurações do Algoritmo Genético

**Rank 1:** Fitness=814.8, Recall=81.48%, FP=33, FN=10, Acc=72.08%, C=34.697, Solver=saga, IQR=1.52, Features=8

**Rank 2:** Fitness=814.8, Recall=81.48%, FP=33, FN=10, Acc=72.08%, C=9.140, Solver=liblinear, IQR=1.52, Features=8

**Rank 3:** Fitness=814.8, Recall=81.48%, FP=33, FN=10, Acc=72.08%, C=30.775, Solver=saga, IQR=1.52, Features=8

**Rank 4:** Fitness=814.8, Recall=81.48%, FP=33, FN=10, Acc=72.08%, C=14.865, Solver=saga, IQR=1.52, Features=7

**Rank 5:** Fitness=814.8, Recall=81.48%, FP=33, FN=10, Acc=72.08%, C=24.320, Solver=liblinear, IQR=1.52, Features=8