

# Relatório de Análise de Resultados

## Régressão Logística e Algoritmos Genéticos

### Tech Challenger 2 - Fase 2

Gerado em: 15/01/2026 16:33:57

## Relatório Técnico

### 1. Resumo Executivo

Este relatório apresenta uma análise detalhada sobre a otimização de um modelo de Régressão Logística para o diagnóstico de diabetes utilizando Algoritmos Genéticos (AG). O experimento demonstrou melhorias significativas nas métricas de desempenho do modelo, principalmente no recall, que passou de 0,50 no modelo original para 0,83 após a otimização. Esta melhoria confirma o potencial dos AGs em ajustar hiperparâmetros de modelos de aprendizado de máquina de forma eficaz.

### 2. Análise da Evolução do Algoritmo Genético

O gráfico de evolução da aptidão demonstra um rápido aumento na função de fitness nas primeiras 20 gerações, seguido por uma estabilização em torno de um valor fitness elevado. Este comportamento é típico em AGs, onde a convergência ocorre após poucas gerações devido à seleção eficiente dos indivíduos mais adequados. Essa estabilização indica que o AG encontrou uma configuração próxima ao ótimo global dentro do espaço de busca.

### 3. Análise Comparativa dos Modelos

A comparação entre o modelo original e o otimizado evidencia melhorias claras. Antes da otimização, o modelo apresentava:

- Baixo recall (0,50)
- Elevada quantidade de falsos negativos (27)

Após a aplicação do AG, o modelo ajustado apresentou:

- Aumento significativo no recall (0,83)
- Redução considerável no número de falsos negativos (9)

Essas mudanças demonstram o impacto positivo da otimização na capacidade do modelo de identificar corretamente os casos positivos de diabetes.

## 4. Análise das Matrizes de Confusão

As matrizes de confusão ilustram visualmente a melhoria na classificação:

- No modelo original, o número de falsos negativos (27) era preocupante.
- O modelo otimizado reduziu bastante os falsos negativos (9), aumentando a confiabilidade do diagnóstico positivo.

Apesar do ligeiro aumento nos falsos positivos no modelo otimizado (20 para 29), a diminuição dos falsos negativos, mais críticos no contexto médico, justifica o trade-off.

## 5. Análise das Métricas de Performance

O gráfico de barras comparativo reforça a melhoria nas métricas de desempenho do modelo otimizado:

- **Recall:** Subiu de 0,50 para 0,83, indicando uma capacidade muito melhorada de identificar corretamente os casos de diabetes.
- **Falsos Positivos:** Aumentaram ligeiramente, mas são gerenciáveis dentro do contexto.
- **Falsos Negativos:** Reduzidos drasticamente, minimizando os riscos associados ao não diagnóstico de casos positivos.

## 6. Conclusões e Insights

A aplicação de Algoritmos Genéticos na otimização de hiperparâmetros de um modelo de Regressão Logística mostrou-se eficaz e vantajosa. As melhorias significativas no recall e na redução de falsos negativos são críticas no contexto clínico de diagnóstico de diabetes, onde a falha em identificar um caso pode ter consequências graves.

## 7. Impacto Prático

Os resultados obtidos têm impacto direto na prática médica, aumentando a eficácia dos diagnósticos de diabetes. A utilização de técnicas de otimização como Algoritmos Genéticos pode ser expandida para outros modelos e condições médicas, contribuindo para diagnósticos mais precisos e para a melhoria geral da saúde pública.

Este estudo reflete um avanço na aplicação de técnicas computacionais avançadas no campo da saúde, demonstrando a sinergia entre tecnologia e medicina para um atendimento mais eficiente e seguro.

## Top 5 Configurações do Algoritmo Genético

**Rank 1:** Fitness=833.3, Recall=83.33%, FP=29, FN=9, Acc=75.32%, C=33.133, Solver=lbfsgs, IQR=1.67, Features=5

**Rank 2:** Fitness=833.3, Recall=83.33%, FP=29, FN=9, Acc=75.32%, C=42.578, Solver=saga, IQR=1.67, Features=5

**Rank 3:** Fitness=833.3, Recall=83.33%, FP=29, FN=9, Acc=75.32%, C=18.251, Solver=liblinear, IQR=1.67, Features=6

**Rank 4:** Fitness=833.3, Recall=83.33%, FP=29, FN=9, Acc=75.32%, C=43.900, Solver=lbfsgs, IQR=1.67, Features=5

**Rank 5:** Fitness=833.3, Recall=83.33%, FP=29, FN=9, Acc=75.32%, C=31.390, Solver=saga, IQR=1.67, Features=5